Effect of unsupervised pretraining in deep reinforcement learning

Michal Chovanec, michal.nand@gmail.com
Peter Šarafín, peter.sarafin@gmail.com

Keywords:reinforcement learning, function approximation, SARSA, Q-learning, neural network, unsupervised training
Abstract:

Článok sa zaoberá vplyvom unsupervised learning na celkový priebeh reinforcement learning tréningu. Ako aproximátor funkcie ohodnotení je zvolená hlboká neurónová sieť. Overovali sme hypotézu, že unsupervised predtrénovaná sieť sa v režime supervised učí rýchlejšie. Zároveň sa ale očakáva, že obe siete po dostatočnom počte iterácií učenia poskytnú rovnaké výsledky. Dalšia testovaná hypotéza je vplyv riedkosti váh na kvalitu výsledku - dnešné technické prostriedky sú navrhnuté na výpočty hustých sieti **TODO citovat**, v budúcnosti, by však hárdverovo akcelerované riedke siete mohli priniest výrazný nárast výkonu **TODO citovat**. Dôležité je preto overiť vplyv riedkych váh na výsledok.

1 Introduction

Reinforcement learning umožuje tránovať agenta v Markovovich rozhodovacích procesov tak aby maximalizoval dosiahnutú odmenu. Tradične sú používané algoritmy Q-learning **TODO citovat** a SARSA **TODO citovat**. V tomto článku je použítý algoritmus SARSA, popísaný ako

$$Q'(s,a) = (1-\alpha)Q(s,a) + \alpha\Big(R(s,a) + \gamma Q(s',a')\Big) \tag{1}$$

kde
$Q(s,a)$ je ohodnotenie akcie a v stave s,
$R(s,a)$ je odmena za vykonanie akcie a v stave s,
$\alpha \in (0,1)$ je rýchlosť učenia,
$\gamma \in \langle 0,1\rangle$ je discount factor,
a $Q'(s,a)$ je nová hodnota ohodnotenia.

Pre malé stavové priestory (väčšinou len učebnicové príklady) je možné použiť tabuľku na uloženie Q hodnôt. Pre veľké stavové priestory - je nevyhnutná aproximácia Q hodnôt. Často používané sú lineárna kombinácia bázových funkcií **TODO citovat** alebo dopredná neurónová sieť **TODO citovat**.
Rekurentná povaha rovnice 1 spôsobuje že učiaci proces je neefektívny a pomalý.
Naša myšlienka je zameraná na unsupervised predtrénovanie siete a až po tom trénovať použitím SARSA algoritmu.

2 Popis experimentu

Agent bol umiestnený do hry znázornenej na obrázku 1. Úlohou je preskakovať a podliezať červené prekážky, agent má teda na výber dve akcie. Prekážky sa generujú náhodne, a postup je sprava do ľava. Za úspešné vyhnutie sa kolízií získa agent odmenu $+0.3$, za neúspech -1.0. Toto je nevyváženie je dôležité, pre kvalitatívne overenie algoritmu, aby náhodnými akciami nikdy nedosiahol kladné skóre.
Stav sú jednotlivé políčka hry, v tomto prípade 5x19 (95 prvkový vektor). Hodnota 0 znamená voľné (biela), hodnota 1 reprezentuje agenta (zelená), a hodnota -1 je zvolená pre prekážku (červená).

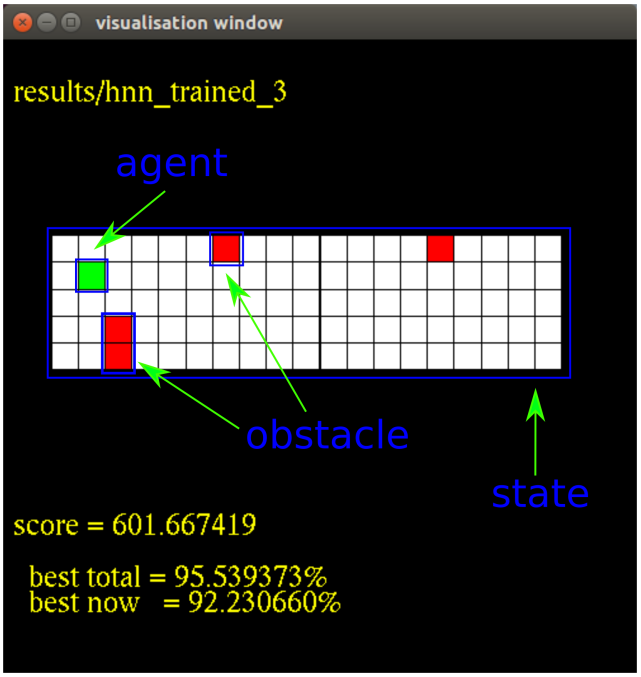

Obr. 1: Testing arcade game

V hre sa sleduje niekoľko veličín. Celkové skóre je dané súčtom jednotlivých odmien. Ďalej sme zaviedli ďalšie dve pomocné veličiny - best_total a best_now.
Veličina best_total ukazuje, koľko percent času volil agent správnu akciu - vyhol sa kolízií, od začiatku behu hry [1].
Veličina best_now ukazuje ukazuje voľbu najlepšej akcie len za posledné obdobie - je použitý priemer s exponenciálnym zabúdaním.

2.1 Topológia siete

Pre porovnanie sme zvolili dve siete. Vstupom je stav hry 5x19 (95 prvkový vektor), výstupom je hodnota $Q(s)$ pre každú akciu - skočit / neskočiť.
Prvá siet je dopredná sieť (FNN) s dvoma skrytými vrstvami, topológia je na obrázku 2. Čísla nad vrstvami sú počty neurónov. Skryté vrstvy majú aktivačnú funkciu ReLU, výstupná vrstva lineárnu aktivačnú funkciu.

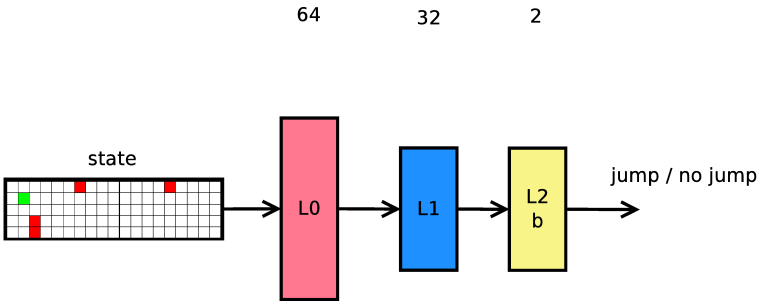

Obr. 2: Supervised network architecture (FNN)

Druhá sieť je tvorená hlbokým autoenkóderom a doprednou sieťou (AE + FNN). Skryté vrstvy majú aktivačnú funkciu ReLU, výstupná vrstva lineárnu aktivačnú funkciu. Jej topológia je na obrázku 3. Vo fáze unsupervised sa trénuje autoenkóder - z 95 prvkového vstupu, postupne extrahuje príznaky, až na počet 32. Následne ďalšie dve vrstvy urobia rekonštrukciu vstupu. Ako učenie sme zovlili metódu stacked autoencoder **TODO citovat**:

[1] Orientačne sme zistili, že ľudský hráč je schopný hrať v intervale od 91% do 93%.

najskôr sa urobí bypass medzi L1 a L2 vrstvami a trénujú sa len vrstvy L0 a L3, po zvolenom počte itererácií sa pripoja vrstvy L1 a L2 a autoenkóder sa dotrénuje.
Po natrénovaní autoenkódera sa odpoja vrstvy L2 a L3. Pripojením vrstvy L2b sa sieť už trénuje supervised, podľa rovnice 1.

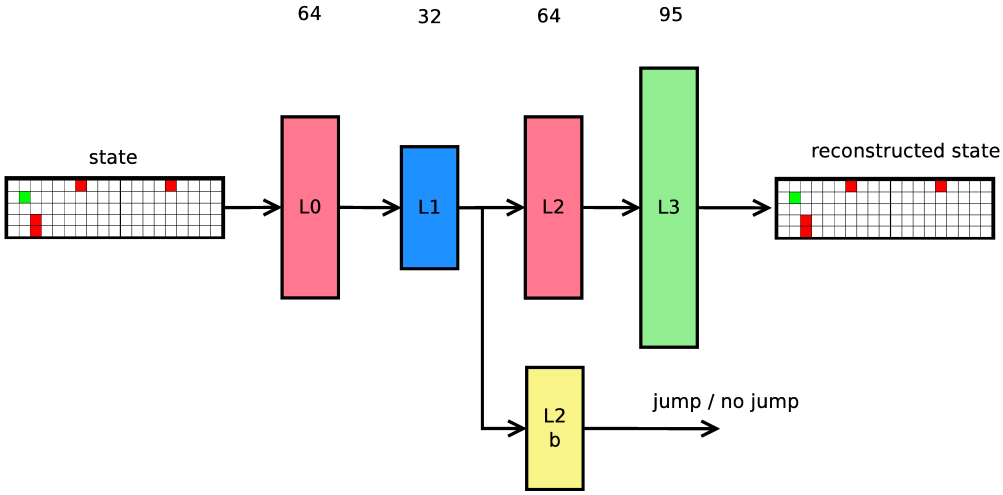

Obr. 3: Unsupervised + Supervised network architecture (AE+FNN)

2.2 Parametre experimentu

Experiment má mnoho parametrov, a bolo potrebné ich zafixovať - dnes nie je možné analyticky stanoviť ich optimálne hodnoty. Hyperparametre sietí boli experimentálne zvolené tak aby nedochádzalo k divergencií váh. Úmerne tomu boli upravené počty iterácií učenia.
Veľkosť batch bol zvolený na 1000 po sebe idúcich stavov. Každý batch mal pri tréningu 10 behov (epoch). Parameter SARSA algoritmu γ bol zvolený 0.8, parameter α je pri použití neurónovej siete ukrytý v learning rate parametry siete.
Siete boli učené algoritmom backpropagation. Riedkosť váh sa dosahovala pomocou L1 normy. Gradientová metóda učenia váh potom prejde na vzťah

$$\Delta w = \eta E x \frac{df(y)}{dw} - \lambda sgn(w) \tag{2}$$

kde
E je chyba neurónu,
x je vstup do neurónu,
y je výstup neurónu,
f je aktivačná funkcia,
η je learning rate ,
λ je parameter riedkosti váh.

Hyperparametre siete sú zhrnuté v tabuľke 1.

Tabuľka 1: Hyperparametre siete

	FNN sparse	FNN no sparse	AE+FNN sparse	AE+FNN no sparse
unsupervised iterations	0	0	100000	100000
supervised iterations	200000	200000	200000	200000
iterations per slice	0	0	50000	50000
learning rate	0.0005	0.0005	0.0005	0.0005
init weight range	0.1	0.1	0.1	0.1
dropout	0	0	0	0
lambda	0.00000001	0	0.00000001	0

Menili sa parametre **unsupervised iterations**, **iterations per slice** a **lambda**. Parameter iterations per slice je počet iterácií na jednu úroveň stacked autoenkódera.

Sputené boli teda 4 rôzne experimenty, každý 5 krát, aby sa vylúčil vplyv počiatočných hodnôt váh a dosiahol sa štatický vierohodný výsledok.

3 Výsledky experimentov

3.1 Riedkosť váh

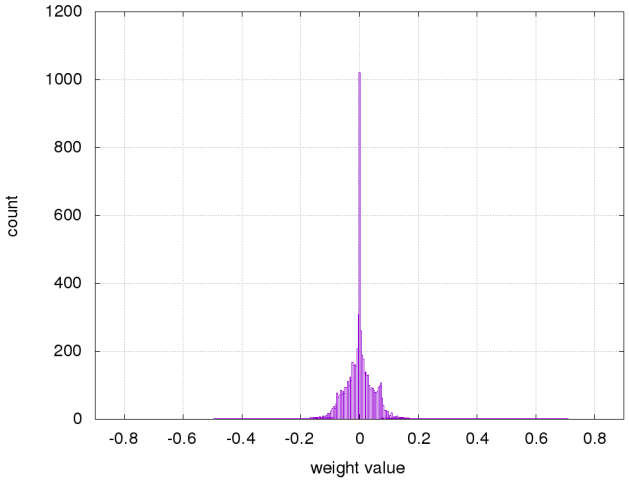

Obr. 4: FNN sparse weights histogram

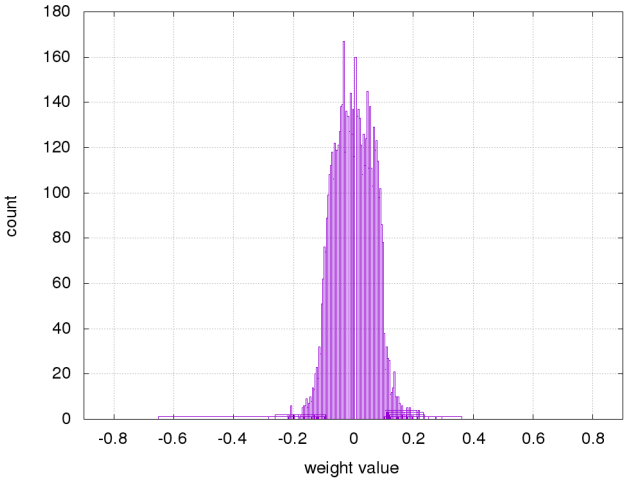

Obr. 5: FNN no sparse weights histogram

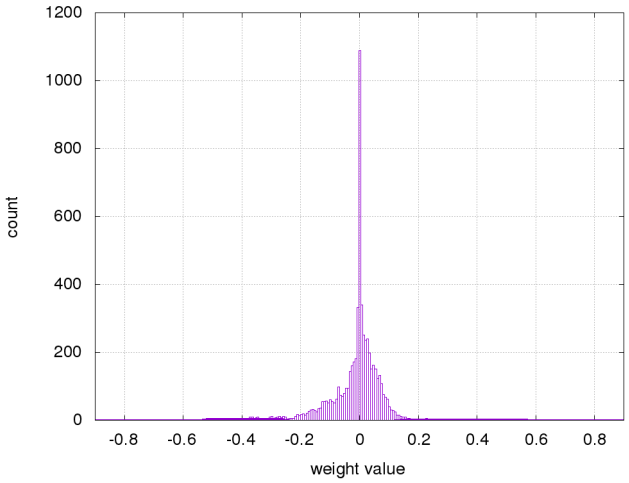

Obr. 6: AE+FNN sparse weights histogram

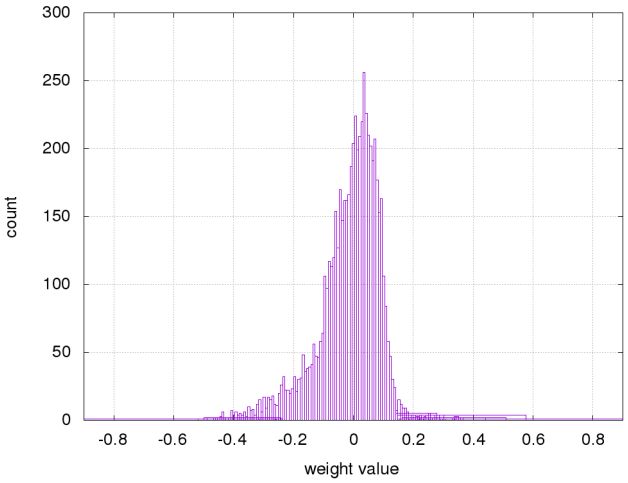

Obr. 7: AE+FNN no sparse weights histogram

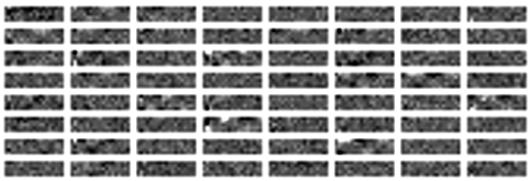

Obr. 8: FNN sparse weights visualisation

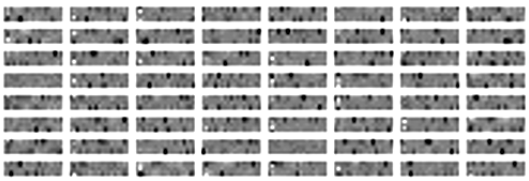

Obr. 9: AE+FNN sparse weights visualisation

3.2 Dosiahnuté skóre

Tabul'ka 2: My caption

	average score	best score	worst score	average best action probability [%]
FNN sparse weights	960.58	994.97	922.64	95.32
FNN nosparse weights	945.04	995.64	878.31	93.29
AE+FNN sparse weights	914.5	947.64	875.31	93.4
AE+FNN no sparse weights	908.58	954.31	780.32	93.12

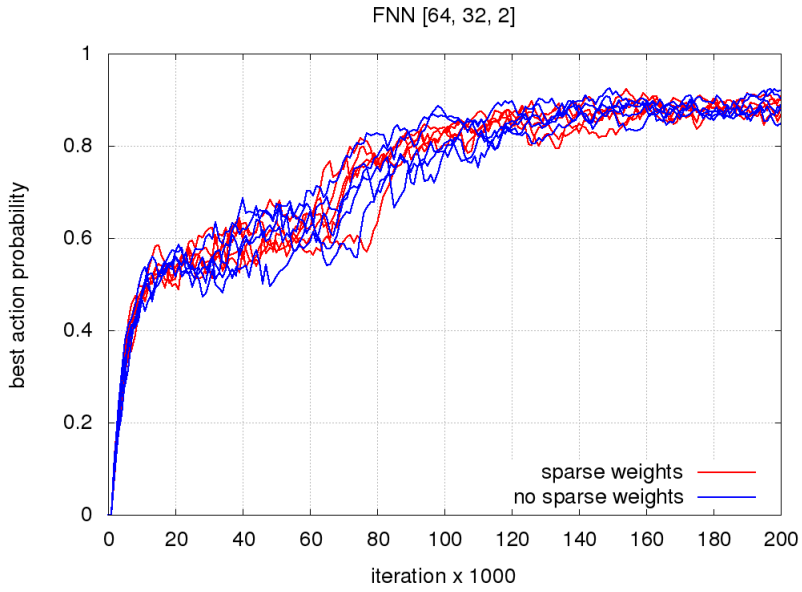

Obr. 10: FNN progress comparison

Obr. 11: AE+FNN progress comparison

4 Conclusion

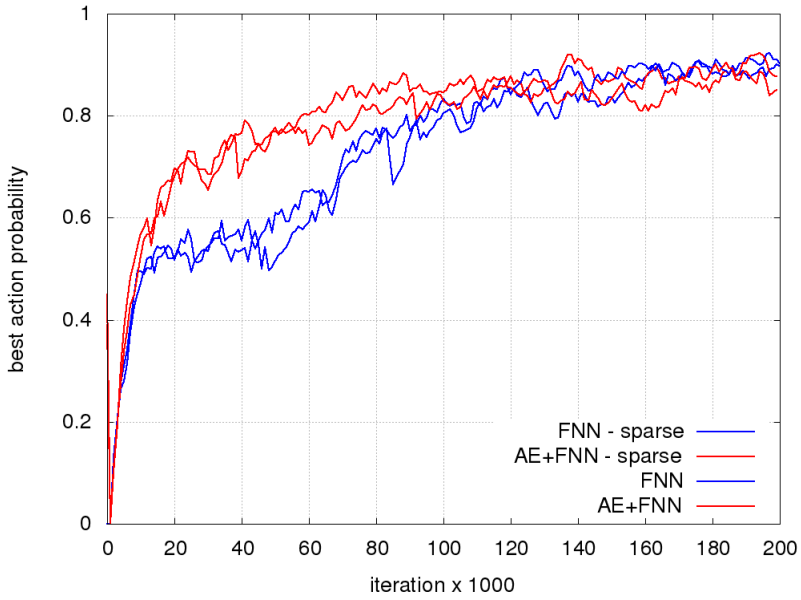

Obr. 12: Training progress comparison

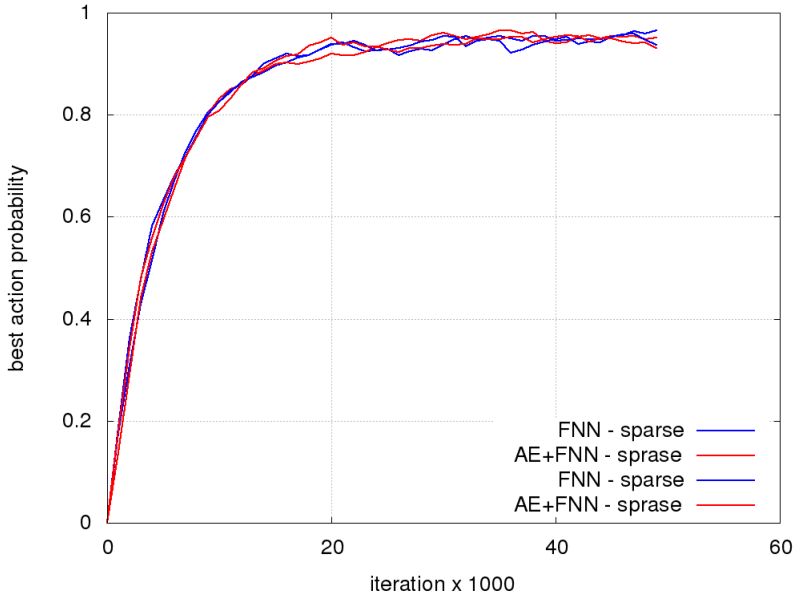

Obr. 13: Testing progress comparison

Literatúra

[1] M.J.Flynn, P.Kanerva, and N.Bhadkamkar, 1989, Sparse Distributed Memory: Principles and Operation http://i.stanford.edu/pub/cstr/reports/csl/tr/89/400/CSL-TR-89-400.pdf

[2] David Rogers, 1988, NASA, KANERVA'S SPARSE DISTRIBUTED MEMORY: AN ASSOCIATIVE MEMORY ALGORITHM WELL SUITED TO THE CONNECTION MACHINE https://pdfs.semanticscholar.org/9288/bb551f000348f800ff40d0fdb3fd74c410ef.pdf

[3] J. S. Albus, 1975, Data Storage in Cerebellar Model Articulation Controller https://www.cs.cmu.edu/afs/cs/academic/class/15883-f13/readings/albus-1975.pdf

[4] Olshausen and Field (1997): Sparse coding with an overcomplete basis set

[5] Olshausen BA, Field DJ (2004) : Sparse coding of sensory inputs. Current Opinion in Neurobiology, 14, 481-487

[6] Mushroom body, locust (Laurent)

[7] HVC, zebra finch (Fee)

[8] Auditory cortex, mouse (DeWeese & Zador)

[9] Hippocampus, ratprimate(Thompson & Best; Skaggs)

[10] Motor cortex, rabbit (Swadlow)

[11] Visual cortex, monkeycat (Vinje & Gallant)

[12] Inferotemporal cortex, human (Fried & Koch)